

Problema L

LLMs

Bruno recentemente começou a se interessar por grandes modelos de linguagem (os chamados LLMs, sigla do termo em inglês, *large language models*). Uma das primeiras coisas que ele aprendeu foi que um dos componentes mais fundamentais das LLMs é o sistema de predição de *tokens* (que, por simplicidade, consideraremos como palavras). A ideia deste tipo de sistema é relativamente simples de explicar: dada uma frase “incompleta”, o sistema deve sugerir a próxima palavra da frase. Tais sistemas se baseiam fortemente em álgebra linear e redes neurais, necessitam de grandes bases de dados de treinamento e possuem no mínimo milhões (muitas vezes bilhões ou até trilhões) de parâmetros, o que torna inviável, para um indivíduo, treinar seu próprio modelo.

Por conta destas limitações (e também pelo fato de não precisar de um LLM em todo seu potencial), Bruno resolveu testar novas ideias, potencialmente mais baratas em termos computacionais, que precisem de menos dados de entrada e que até eliminem a fase de treinamento. Ele não espera obter algo tão bom quanto os modelos comerciais, mas acha que pode encontrar um modelo muito mais barato e suficientemente bom. Ele precisa de ajuda para testar o sistema de predição de palavras que acabou de conceber.

Seu sistema, batizado de Sistema Bruno de Chat ou, simplesmente, SBC, começa de forma similar aos LLMs tradicionais: ele recebe como entrada um mapeamento de um conjunto de palavras, chamado de “dicionário”, em um espaço euclidiano, que de alguma forma tende a codificar palavras similares em pontos próximos. Este dicionário vem ordenado da palavra mais comum para a menos comum, no conjunto de dados utilizado para construí-lo. Por simplicidade, Bruno fez uma projeção deste espaço em um plano e arredondou as coordenadas, de forma que cada palavra p seja representada por um ponto (ou vetor) $v(p)$ com coordenadas inteiras no $\mathbb{R}^2$. Além deste mapeamento, Bruno utilizará um texto de entrada como sua “base de conhecimento”, ou seja, a fonte a partir da qual suas perguntas serão respondidas.

Para cada consulta, ele tentará prever a próxima palavra. Para isso, ele olhará as últimas palavras da consulta e, utilizando o mapeamento e o texto, fará a previsão de qual palavra deve ser utilizada.

O sistema de Bruno funciona da seguinte forma. Inicialmente, é escolhido um inteiro K , que será o tamanho da “janela de contexto”. Para as K últimas palavras da consulta, buscaremos, na base de conhecimento, onde estas palavras ocorrem no texto, exatamente na mesma ordem e de forma consecutiva. Em cada ocorrência, registramos a palavra c que ocorre na base de conhecimento logo após as K últimas palavras. Após repetir este processo por todo o texto, obtemos uma sequência $c_1, \dots, c_r$ de palavras, que chamaremos de “candidatas”.

Em seguida, para cada palavra d do dicionário, é calculada a similaridade de d com as candidatas. Como as palavras estão associadas a vetores, e o produto interno de dois vetores pode ser interpretado como uma medida de similaridade entre eles, Bruno decidiu utilizá-lo como métrica de similaridade. Por abuso de notação, identificamos cada palavra com seu vetor: $d \equiv v(d)$ e $c_i \equiv v(c_i)$. O produto interno de dois vetores $v = (v_x, v_y)$ e $w = (w_x, w_y)$ é denotado por $v \cdot w$ e é definido como $v \cdot w = v_x w_x + v_y w_y$. A similaridade de uma palavra d do dicionário com as candidatas é dada por

$$S(d) = \sum_{i=1}^r d \cdot c_i.$$

O SBC então escolhe a palavra com maior valor de $S(d)$ e esta será a próxima palavra do texto. Em caso de empate, o SBC escolherá a palavra mais comum, ou seja, a que aparece primeiro no dicionário. Caso não haja nenhuma palavra candidata, o valor de K é diminuído de uma unidade e o processo é feito novamente. Caso nem mesmo para $K = 1$ haja palavras candidatas, o processo é abortado.

Muito embora na intuição de Bruno todo este processo faça sentido, ele tem muita dificuldade para implementá-lo e precisa de sua ajuda.

Entrada

A entrada contém 3 partes: a primeira descrevendo o dicionário, a segunda descrevendo a base de conhecimento e a terceira contendo as consultas.

A primeira linha da entrada contém um inteiro N ($2 \leq N \leq 10^3$), indicando o número de palavras do dicionário. A i -ésima das N linhas seguintes conterá uma palavra P_i composta apenas por letras minúsculas do alfabeto, com no máximo 12 caracteres, seguida de dois números inteiros X_i e Y_i ($-10^3 \leq X_i, Y_i \leq 10^3$), que indicam o vetor (X_i, Y_i) associado à i -ésima palavra do dicionário.

A linha seguinte contém um inteiro M ($2 \leq M \leq 10^3$), o número de palavras no texto correspondente à base de conhecimento. As linhas seguintes conterão a base de conhecimento, com 8 palavras por linha, separadas por espaço (exceto, possivelmente, na última linha).

Em seguida, dois inteiros Q ($1 \leq Q \leq 10$) e K ($1 \leq K \leq 5$), indicando o número de consultas e o tamanho da janela de contexto. Cada uma das linhas seguintes descreverá uma consulta. Cada consulta conterá um inteiro F ($K \leq F \leq 8$), seguido de F palavras.

Saída

Para cada consulta, deverá ser impressa uma linha contendo as palavras da consulta seguidas da próxima palavra prevista pelo SBC, se existir, ou seguidas de “*” (asterisco), caso contrário.

Exemplo de entrada 1

```
6
the -15 0
world 7 6
star -4 2
wars 10 12
peace 10 -11
trek 13 1
12
the peace the war the trek the star
star wars star peace
4 3
3 i love star
3 this is the
4 star trek is very
3 star star star
```

Exemplo de saída 1

```
i love star trek
this is the peace
star trek is very *
star star star wars
```